TỔNG QUAN DỰ ÁN

Một nền tảng. Nhiều trợ lý AI.

Hỗ trợ cán bộ và lãnh đạo trên dữ liệu có căn cứ.

Mở rộng: NCKH · HTQT · Nhân sự · Hành chính

15 PHÚT · TỔNG THỂ / VẬN HÀNH / CHI PHÍ / BẢO MẬT

Demo: proxyllm.store · 106 văn bản công khai · số liệu nghiệp vụ giả lập

Tuyển sinh

Tra cứu và số liệu

Đào tạo

Quy chế và học vụ

Tổng hợp

Giao việc liên lĩnh vực

02 / GIÁ TRỊ SỬ DỤNG

Con người tự làm và có Credere hỗ trợ

AI hỗ trợ thao tác lặp lại; con người giữ quyền hiểu bối cảnh và phê duyệt.

Công đoạn	Tự làm	Có Credere hỗ trợ
Tìm và lấy dữ liệu	Mở văn bản, lọc bảng, hỏi đầu mối	Tra nguồn / chọn truy vấn định sẵn
Ghép nhiều đơn vị	Chờ từng đầu mối rồi ghép	Giao AI con, kết hợp khi đầu vào đạt
Tính và viết	Tính toán, lập bảng, soạn báo cáo	Code tính; AI viết nháp có nguồn
Kiểm tra và quyết định	Cán bộ kiểm tra, lãnh đạo duyệt	Vẫn do cán bộ và lãnh đạo chịu trách nhiệm

03 / CÁCH HOẠT ĐỘNG

Kiến trúc toàn bộ hệ thống

Tách giao diện, điều phối, dữ liệu và nơi chạy model để có thể thay từng phần.

Giao diện web

Hỏi đáp · nguồn · CSV · tiến độ

→

Điều phối

Master · kế hoạch · nghiệm thu

→

AI lĩnh vực

Tuyển sinh · Đào tạo · Phân tích

→

Nguồn và model

JSON / SQLite · gateway API

Nginx + HTTPS → FastAPI / LangGraph → dữ liệu theo lĩnh vực

Model hiện qua API; local là phương án bổ sung cần kiểm chứng.

Đang chạy: FastAPI + LangGraph + SQLite, sau Nginx/systemd trên VPS. Chưa có SSO và checkpoint bền.

03 / CÁCH HOẠT ĐỘNG

AI Hiệu trưởng giao việc thật cho AI con

Cấp Tổng hợp không được nạp toàn bộ dataset của hai AI lĩnh vực.

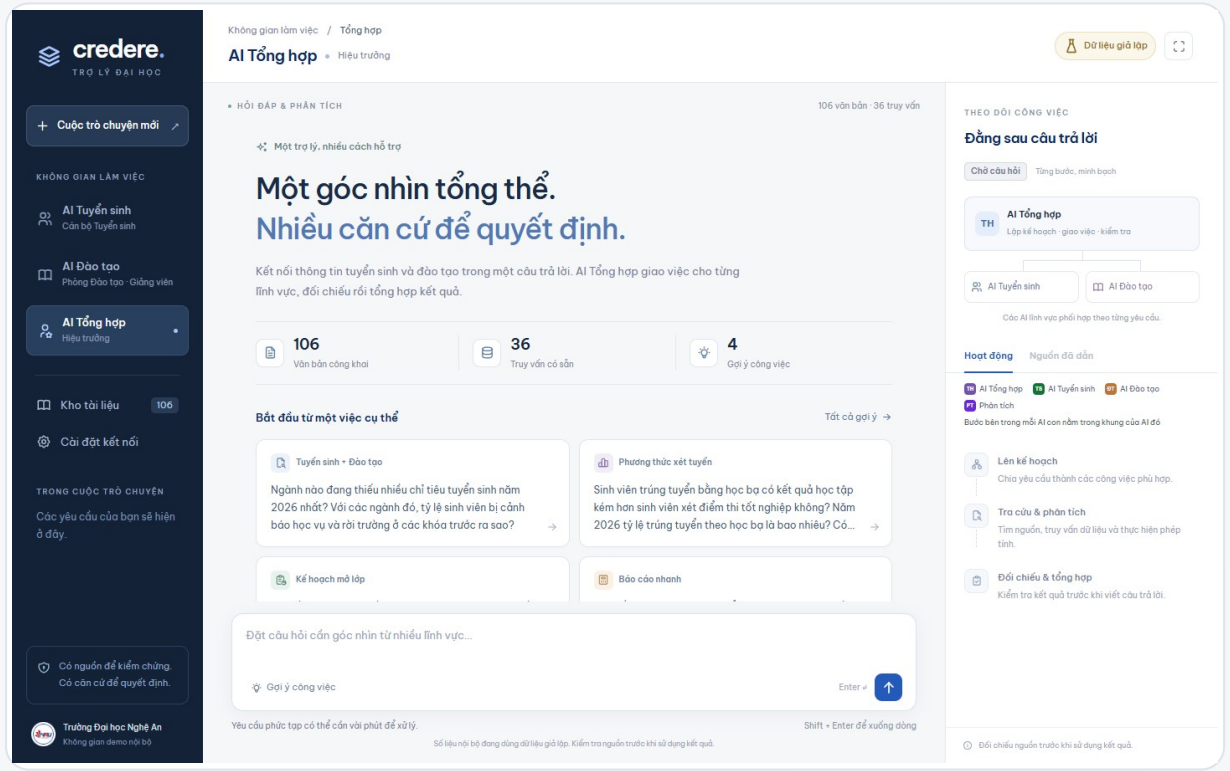


Bản ghi 29/9: hai AI con có kế hoạch riêng; T3 đợi T1 + T2; 18 lượt gọi, 4 phút 47 giây.

03 / DEMO

Trình diễn trên tên miền đã triển khai

https://proxyllm.store — nhập yêu cầu mới, xem giao việc và mở nguồn.



Giới hạn demo 2 phút 30 giây; nếu chưa xong, tiếp tục bài và dùng ảnh dự phòng khi cần.

Demo proxyllm.store

Quan sát

AI nào nhận việc; phụ thuộc nào phải đợi.

Kiểm chứng

Nguồn dẫn, mốc dữ liệu và phần hạn chế.

04 / PHƯƠNG ÁN API VÀ LOCAL

Ba lựa chọn nơi xử lý model

Nơi đặt web/CSDL và nơi suy luận AI có thể khác nhau.

Tiêu chí	API trực tiếp	Local tại trường	Lai
Vốn ban đầu	Thấp; không mua GPU	Máy/GPU, lưu trữ, dự phòng	Có phần hạ tầng local
Vận hành model	Nhà cung cấp đảm nhận	Đội trường tự vận hành	Quản cả hai tuyến
Dữ liệu prompt	Ra API được duyệt	Ở hạ tầng trường nếu cấu hình kín	Theo chính sách từng tác vụ
Đánh đổi	Phụ thuộc mạng / nhà cung cấp	VRAM, tải, bảo trì, chất lượng	Chính sách và tích hợp phức tạp

04 / CHI PHÍ API

API OpenAI: giá và cách tính một yêu cầu

Cộng mọi lời gọi trong một Run; API trực tiếp và giá gateway hiện tại là hai kênh khác nhau.

Model / vai trò dự kiến	Input / 1M	Output / 1M	Phạm vi giá
GPT-6 Sol · Master/review	$2,00	$10,00	Standard · short context
GPT-6 Luna · Worker	$0,10	$0,50	Standard · short context

Một câu hỏi người dùng = nhiều lời gọi AI.
Tính tổng Master + Worker + sửa + tổng hợp.

Ví dụ tổng Master 20k/2k + Worker 30k/2k → $0,064 ≈ 1.728 đ/Run; tỷ giá giả định 27.000 đ/USD.

04 / CHI PHÍ LOCAL

Model local: chủ động dữ liệu, thêm công vận hành

Ứng viên Qwen3 + Ollama/vLLM; cần benchmark trên máy thực trước khi mua.

Thành phần minh họa	Cách tính	Chi phí
Máy / GPU trọn bộ	150 triệu / 36 tháng	4,17 triệu/tháng phân bổ
Công + điện + bảo trì	2 + 0,5 + 0,5 triệu	3,00 triệu/tháng
Tổng sở hữu quy đổi	4,17 + 3,00	7,17 triệu/tháng
Tiền chi năm đầu	150 + 3 × 12	186 triệu

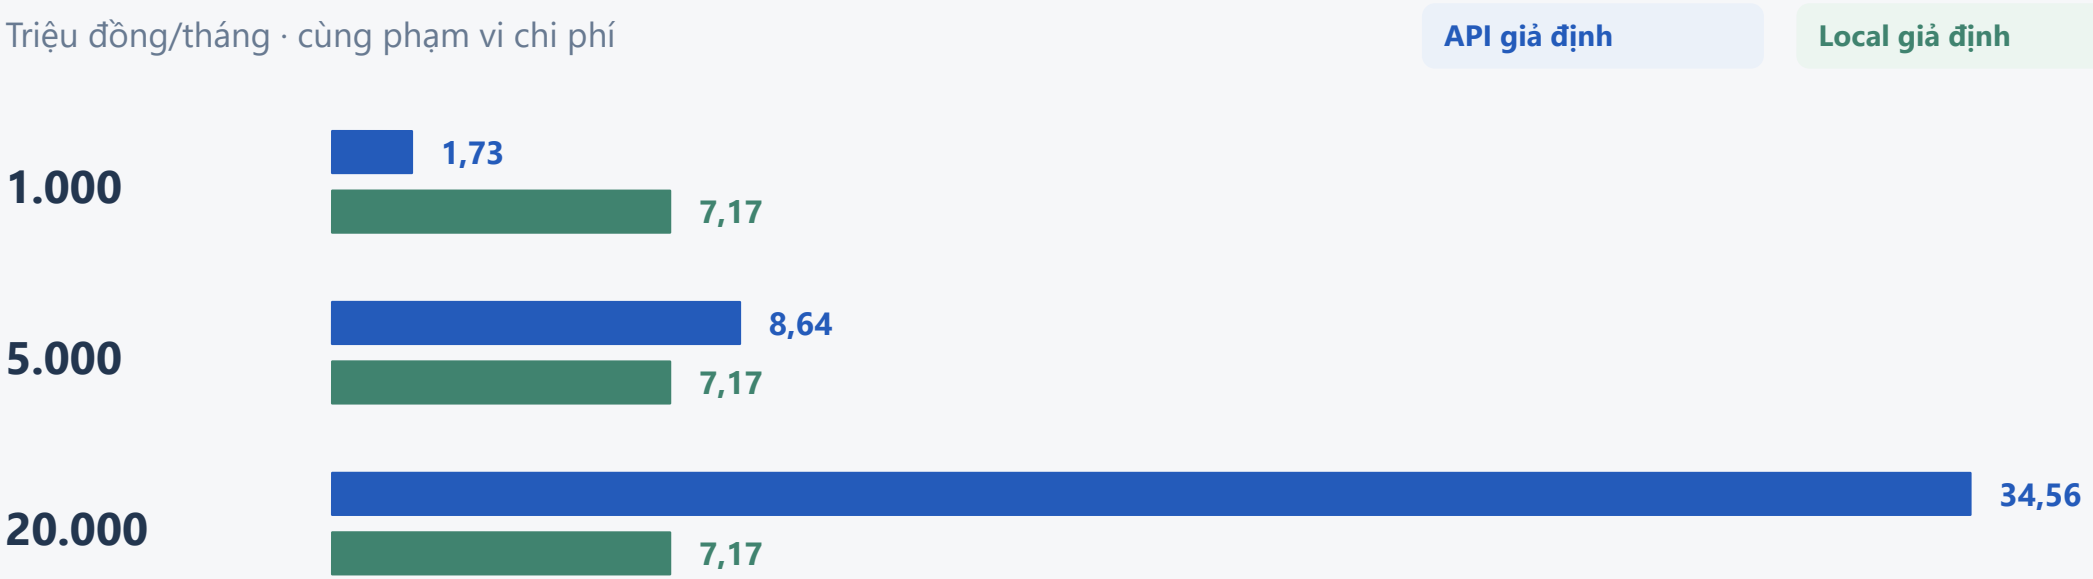
Thuê thử A40: $0,49/h × 176h × 27.000 ≈ 2,33 triệu; GPU cloud có vị trí/hợp đồng riêng.

04 / QUYẾT ĐỊNH ĐẦU TƯ

So chi phí công bằng: cùng tải, cùng chất lượng

Bảng chỉ so phần suy luận AI; chưa chứng minh máy local đạt cùng chất lượng và công suất.

Triệu đồng/tháng · cùng phạm vi chi phí



Giao điểm giả định ~4.147 yêu cầu/tháng; chưa phải hòa vốn đã chứng minh.

Local ở các tải trên chưa được benchmark. Phải so chi phí trên công việc được chấp nhận, không chỉ giá token.

04 / PHƯƠNG ÁN ĐỀ XUẤT

Phương án C: kết hợp API và model nội bộ

Chọn tuyến theo chính sách dữ liệu; không chuyển cloud chỉ vì model local gặp lỗi.

01 **Dữ liệu được phép xuất**

API trực tiếp, tài khoản do Trường quản lý.

02 **Bắt buộc giữ nội bộ**

Model local + truy vấn/nguồn trong vùng kiểm soát.

03 **Điều phối xuyên suốt**

Cả Master, AI con, review và tổng hợp tuân chính sách.

04 **Khi xảy ra lỗi**

Local-only không tự fallback ra API ngoài.

Đề xuất tích hợp; hiện mới có lọc nhà cung cấp theo nhãn trusted, chưa có local-only policy.

05 / BẢO MẬT THÔNG TIN NHÀ TRƯỜNG

Phân loại thông tin trước khi chọn tuyến AI

Đơn vị sở hữu dữ liệu quyết định ai được xem, được tổng hợp và được gửi đi.

Mức đề xuất	Ví dụ	Nguyên tắc xử lý
Công khai	Quy chế, thông báo đã công bố	API được duyệt; kiểm phiên bản
Nội bộ	Thống kê vận hành chưa công bố	Theo quyền và danh mục được phép xuất
Hạn chế / nhạy cảm	Hồ sơ, điểm, liên hệ, nhân sự	Giữ nội bộ khi chính sách yêu cầu
Mọi mức	Câu hỏi, log, báo cáo và CSV	Cùng chính sách truy cập và thời hạn lưu

Phân loại là đề xuất quản trị dữ liệu; phải được đơn vị chủ dữ liệu xác nhận.

05 / BẢO MẬT THÔNG TIN NHÀ TRƯỜNG

Bảo mật: từ cài đặt đến dữ liệu nghiệp vụ

Mật khẩu cài đặt đã có; quyền đọc/xuất dữ liệu theo người dùng vẫn phải bổ sung.

Lớp	Việc cần thực hiện	Bằng chứng nghiệm thu
Danh tính / quyền	SSO, vai trò; kiểm API, nguồn, CSV	Thử cho phép/từ chối/thu hồi
Dữ liệu gửi model	Lọc câu hỏi, log, nhóm nhỏ; local-only	Không lộ PII hoặc đi sai tuyến
Hạ tầng / bí mật	TLS, CSDL riêng, key, hạn mức	Kiểm cổng, quyền và thu hồi key
Vận hành	Log có hạn lưu; backup mã hóa; restore	Diễn tập sự cố và khôi phục

Đề xuất pilot; hiện chưa có phân quyền hỏi đáp theo người dùng. Chi tiết chính sách API ở phụ lục A5.

06 / KẾ HOẠCH TRIỂN KHAI

Kế hoạch đề xuất trong 12 tuần

Mỗi giai đoạn có đầu ra và điều kiện chuyển tiếp; thời gian phụ thuộc dữ liệu và nhân sự.

Giai đoạn	Công việc chính	Đầu ra / điều kiện đạt
Tuần 1–2 · Chốt đầu vào	Phỏng vấn, nguồn, quyền, đo nền	Bộ việc ưu tiên + nguồn được duyệt
Tuần 3–5 · Nền tảng	SSO/quyền, nhập nguồn, truy vấn	Test đọc/xuất dữ liệu đúng quyền
Tuần 6–8 · Hoàn thiện	Phối hợp, phục hồi, so API/local	Qua kiểm thử lỗi và chất lượng
Tuần 9–12 · Pilot	Câu mới, cán bộ chấm, đo chi phí	Biên bản đạt / điểm phải sửa

Lịch đề xuất 10–12/2026, cần chốt năng lực nhóm, dữ liệu và lịch nghiệm thu với Nhà trường.

06 / KẾ HOẠCH TRIỂN KHAI

Nghiệm thu bằng công việc thật và người phụ trách

Đầu mối nghiệp vụ duyệt nguồn; CNTT vận hành; nhóm phát triển sửa; lãnh đạo nghiệm thu.

01 Chất lượng

Câu mới; cán bộ chấm nguồn, số và suy luận theo rubric.

02 Quyền / an toàn

Không đọc/xuất trái quyền trong bộ thử; kiểm injection.

03 Bền vững

Thử lỗi, khởi động lại, backup/restore và hạn mức.

04 Giá trị sử dụng

Đo thời gian có kiểm/sửa và chi phí Run đạt.

Mỗi báo cáo đạt cần đúng nguồn, số và phạm vi; thử sai quyền không có rò rỉ. Mục tiêu chất lượng phải chốt trước.

07 / KẾT LUẬN VÀ ĐỀ NGHỊ

Đề xuất lựa chọn và các quyết định cần chốt

Bắt đầu bằng API cho dữ liệu được phép; benchmark local trước khi mua; bảo mật trước pilot.

01 **Chọn phạm vi**

Hai đầu mối Tuyển sinh/Đào tạo; công việc ưu tiên cụ thể.

02 **Chọn dữ liệu**

Nguồn được duyệt, quyền và chính sách API/local.

03 **Chọn ngân sách**

Tải dự kiến + nhân công + hạ tầng + dự phòng.

04 **Chọn điều kiện mở rộng**

Câu hỏi độc lập, biên bản nghiệm thu và người vận hành.

01 / BỨC TRANH TỔNG THỂ

A1 · Sáu lĩnh vực và trạng thái hiện tại

Đã có hai AI lĩnh vực và AI Tổng hợp; các lĩnh vực khác mở theo điều kiện dữ liệu.

Phạm vi	Hiện trạng	Điều kiện tiếp theo
Tuyển sinh	70 văn bản · 19 truy vấn	Hiệu chỉnh với dữ liệu được duyệt
Đào tạo	36 văn bản · 17 truy vấn	Chốt quy chế theo khóa, định nghĩa chỉ số
NCKH / HTQT	Khung tổng quát; chưa đủ nghiệp vụ	Nguồn học thuật, dữ liệu và rubric
Nhân sự / Hành chính	Chưa triển khai ứng dụng	Ma trận quyền và nguồn nội bộ

AI Tổng hợp đang kết nối Tuyển sinh + Đào tạo. Số liệu nghiệp vụ hiện là giả lập.

04 / PHƯƠNG ÁN API VÀ LOCAL

A2 · Ứng viên và cấu hình thử model local

Local tăng quyền kiểm soát nơi xử lý; không tự động bảo đảm chất lượng hay an toàn.

Ứng viên	Mốc thử ban đầu*	Lợi ích / đánh đổi
Qwen3-8B	GPU 16–24 GB	Nhẹ hơn; phải thử độ đúng và tiếng Việt
Qwen3-14B	GPU 24 GB	Thử Worker và Master, theo ngữ cảnh
Qwen3-32B	GPU 48 GB	Tốn bộ nhớ hơn; chưa đo năng lực phục vụ
Ollama / vLLM	API tương thích để tích hợp	Không bảo đảm cùng chất lượng với API

*VRAM là ước lượng để chọn bài thử, không phải cam kết cấu hình. Đo KV cache và số phiên trước khi mua.

PHỤ LỤC KIỂM TRA SỐ LIỆU

A3 · Giả định và phép tính chi phí

Thay giả định bằng số đo thực tế và báo giá trước khi quyết định ngân sách.

Khoản	Giả định	Kết quả
Master	20k vào × $2 + 2k ra × $10	0,060 USD
Worker	30k vào × $0,1 + 2k ra × $0,5	0,004 USD
Toàn Run	0,064 USD × 27.000 đ/USD	1.728 đ
Local	150 triệu / 36 + 3 triệu	7,167 triệu/tháng

03 / KIỂM CHỨNG

A4 · Kết quả nội bộ và giới hạn bộ chấm

Kiểm thử phần mềm và đánh giá chất lượng nghiệp vụ là hai loại bằng chứng khác nhau.

Bằng chứng	Kết quả ghi nhận	Ý nghĩa / giới hạn
Test phần mềm	159 test đạt	Luồng và ràng buộc; model giả lập
Văn bản Tuyển sinh	30/30	Bộ nội bộ có đáp án
Dữ liệu Tuyển sinh	14/14	CSDL giả lập
Đào tạo / Tổng hợp	10/10 và 4/4	Mẫu nhỏ, chưa nghiệm thu độc lập

05 / BẢO MẬT THÔNG TIN NHÀ TRƯỜNG

A5 · Chính sách dữ liệu của OpenAI API

Không dùng dữ liệu để huấn luyện không đồng nghĩa không lưu giữ.

01 **Huấn luyện**

API không dùng để huấn luyện mặc định, trừ khi opt-in.

02 **Lưu giữ**

Log mặc định có thể đến 30 ngày; endpoint có trạng thái riêng.

03 **ZDR**

Cần phê duyệt, có điều kiện và giới hạn tính năng.

04 **Trước khi dùng**

Duyệt nhà cung cấp, hợp đồng, vùng xử lý và loại dữ liệu.

Nguồn OpenAI API kiểm tra 29/09/2026; không áp dụng thay cho chính sách gateway khác.

05 / BẢO MẬT THÔNG TIN NHÀ TRƯỜNG

A6 · Kiểm soát toàn bộ luồng dữ liệu

Tổng hợp số liệu giảm phơi bày, nhưng không tự động bảo đảm ẩn danh.

01 **Đã có trong truy vấn**

Danh sách cá nhân tách khỏi đầu vào model; CSDL chỉ đọc.

02 **Cần thêm**

Kiểm câu hỏi, nguồn, tham số, báo cáo, log và bản ghi.

03 **Chống suy danh tính**

Nhóm nhỏ, suy từ tổng và chuỗi truy vấn; ngưỡng phải duyệt.

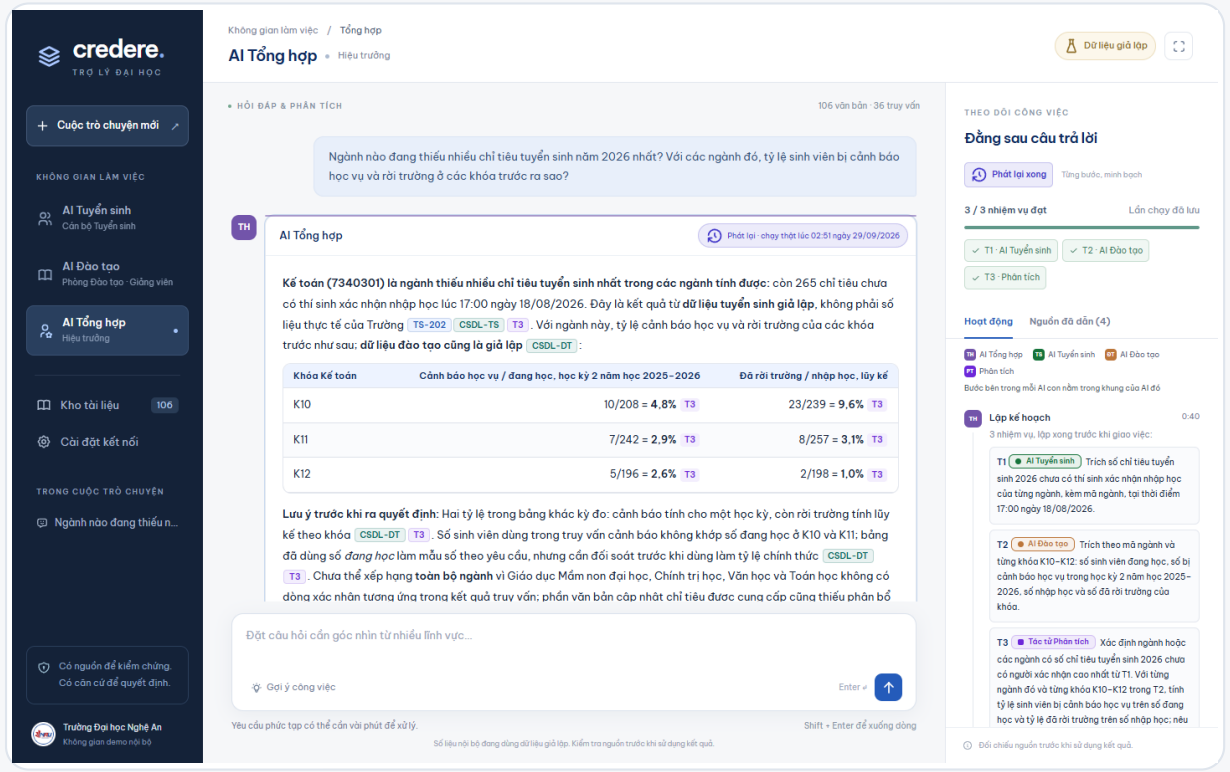
04 **Chống chèn chỉ dẫn**

Tài liệu không được cấp quyền/công cụ; có bộ thử tấn công.

PHỤ LỤC DEMO

A7 · Ảnh kết quả Tổng hợp để dự phòng

Ảnh của lượt chạy đã lưu; không phải kết quả vừa gọi AI trong buổi trình bày.



Demo proxyllm.store

Nguồn ảnh

Lượt chạy đã lưu

Dữ liệu

Nghiệp vụ giả lập

PHỤ LỤC BÀN GIAO

A8 · Đối chiếu yêu cầu và nguồn tham khảo

Mọi ý trong yeucauslide.txt có mục riêng; lời nói chi tiết nằm trong Notes và tài liệu kèm.

Nội dung bắt buộc	Căn cứ
Tổng thể / cơ chế / lợi ích	Code, PLAN, hồ sơ chạy; cách đo đề xuất
Triển khai / kế hoạch	VPS hiện tại + giai đoạn có điều kiện
API / local / chi phí	Tài liệu chính thức + giả định hiển thị
Bảo mật thông tin	Code hiện tại + phương án pilot có kiểm thử